

Загрузить необходимые библиотеки

```
!pip install adversarial-robustness-toolbox

Collecting adversarial-robustness-toolbox
  Downloading adversarial_robustness_toolbox-1.17.0-py3-none-any.whl
(1.7 MB)
----- 1.7/1.7 MB 16.2 MB/s eta
0:00:00
Requirement already satisfied: numpy>=1.18.0 in
/usr/local/lib/python3.10/dist-packages (from adversarial-robustness-
toolbox) (1.23.5)
Requirement already satisfied: scipy>=1.4.1 in
/usr/local/lib/python3.10/dist-packages (from adversarial-robustness-
toolbox) (1.11.4)
Collecting scikit-learn<1.2.0,>=0.22.2 (from adversarial-robustness-
toolbox)
  Downloading scikit_learn-1.1.3-cp310-cp310-
manylinux_2_17_x86_64.manylinux2014_x86_64.whl (30.5 MB)
----- 30.5/30.5 MB 34.2 MB/s eta
0:00:00
Requirement already satisfied: six in /usr/local/lib/python3.10/dist-packages
(from adversarial-robustness-toolbox) (1.16.0)
Requirement already satisfied: setuptools in
/usr/local/lib/python3.10/dist-packages (from adversarial-robustness-
toolbox) (67.7.2)
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-
packages (from adversarial-robustness-toolbox) (4.66.1)
Requirement already satisfied: joblib>=1.0.0 in
/usr/local/lib/python3.10/dist-packages (from scikit-
learn<1.2.0,>=0.22.2->adversarial-robustness-toolbox) (1.3.2)
Requirement already satisfied: threadpoolctl>=2.0.0 in
/usr/local/lib/python3.10/dist-packages (from scikit-
learn<1.2.0,>=0.22.2->adversarial-robustness-toolbox) (3.2.0)
Installing collected packages: scikit-learn, adversarial-robustness-
toolbox
  Attempting uninstall: scikit-learn
    Found existing installation: scikit-learn 1.2.2
    Uninstalling scikit-learn-1.2.2:
      Successfully uninstalled scikit-learn-1.2.2
ERROR: pip's dependency resolver does not currently take into account
all the packages that are installed. This behaviour is the source of
the following dependency conflicts.
bigframes 0.19.1 requires scikit-learn>=1.2.2, but you have scikit-
learn 1.1.3 which is incompatible.
Successfully installed adversarial-robustness-toolbox-1.17.0 scikit-
learn-1.1.3
```

Подключаем библиотеки

```

from __future__ import absolute_import, division, print_function,
unicode_literals
import os, sys
from os.path import abspath
module_path = os.path.abspath(os.path.join('..'))
if module_path not in sys.path: sys.path.append(module_path)
import warnings
warnings.filterwarnings('ignore')
import tensorflow as tf
tf.compat.v1.disable_eager_execution()
tf.get_logger().setLevel('ERROR')
import tensorflow.keras.backend as k
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Flatten, Conv2D,
MaxPooling2D, Activation, Dropout
import numpy as np
import matplotlib.pyplot as plt
%matplotlib inline
from art.estimators.classification import KerasClassifier
from art.attacks.poisoning import PoisoningAttackBackdoor,
PoisoningAttackCleanLabelBackdoor
from art.attacks.poisoning.perturbations import add_pattern_bd
from art.utils import load_mnist, preprocess, to_categorical
from art.defences.trainer import AdversarialTrainerMadryPGD

```

```

from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense,
Flatten, Conv2D, MaxPooling2D, Activation, Dropout)
Сверточный слой кол-во фильтров = 32,
размер фильтра (3,3), активация = relu;
Сверточный слой кол-во фильтров = 64, размер
фильтра (3,3), активация = relu;
Слой пулинга с размером (2,2); Дропаут(0,25);
Слой Выравнивания (Flatten);
Полносвязный слой размером = 128, активация = relu;
Дропаут(0,25);
Полносвязный слой размером = 10, активация = softmax;
Скомпилировать модель:
model.compile(loss='categorical_crossentropy', optimizer='adam',
metrics=['accuracy'])

```

Загрузить датасет:

```

(x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ =
load_mnist(raw=True)
n_train = np.shape(x_raw)[0]
num_selection = 10000
# выбираем случайный индекс
random_selection_indices = np.random.choice(n_train, num_selection)
x_raw = x_raw[random_selection_indices]
y_raw = y_raw[random_selection_indices]

```

Выполнить предобработку данных:

```

# фиксируем коэффициент отравления
percent_poison = .33

```

```

# отправляем обучающие данные
x_train, y_train = preprocess(x_raw, y_raw)
x_train = np.expand_dims(x_train, axis=3)
# отправляем данные для теста
x_test, y_test = preprocess(x_raw_test, y_raw_test)
x_test = np.expand_dims(x_test, axis=3)
# фиксируем обучающие классы
n_train = np.shape(y_train)[0]
# перемешиваем обучающие классы
shuffled_indices = np.arange(n_train)
np.random.shuffle(shuffled_indices)
x_train = x_train[shuffled_indices]
y_train = y_train[shuffled_indices]

```

Написать функцию create\_model(): для создания последовательной модели из 9 слоев (см. пункт а) from tensorflow.keras.models import Sequential from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Activation, Dropout) Сверточный слой кол-во фильтров = 32, размер фильтра (3,3), активация = relu; Сверточный слой кол-во фильтров = 64, размер фильтра (3,3), активация = relu; Слой пулинга с размером (2,2); Дропаут(0,25); Слой Выравнивания (Flatten); Полносвязный слой размером = 128, активация = relu; Дропаут(0,25); Полносвязный слой размером = 10, активация = softmax; Скомпилировать модель: model.compile(loss='categorical\_crossentropy', optimizer='adam', metrics=['accuracy'])

```

def create_model():
    # объявляем последовательную модель
    model = Sequential()
    # добавляем сверточный слой 1
    model.add(Conv2D(32, (3,3), activation='relu', input_shape=(28, 28, 1)))
    # добавляем сверточный слой 2
    model.add(Conv2D(64, (3,3), activation='relu'))
    # добавляем слой пулинга
    model.add(MaxPooling2D((2,2)))
    # добавляем дропаут 1
    model.add(Dropout(0.25))
    # добавляем слой выравнивания
    model.add(Flatten())
    # добавляем полносвязный слой 1
    model.add(Dense(128, activation = 'relu'))
    # добавляем дропаут 2
    model.add(Dropout(0.25))
    # добавляем полносвязный слой 2
    model.add(Dense(10, activation = 'softmax'))
    # компилируем модель
    model.compile(loss='categorical_crossentropy', optimizer='adam',
metrics=['accuracy'])
    # возвращаем скомпилированную модель
    return model

```


```

#Создать атаку
backdoor = PoisoningAttackBackdoor(add_pattern_bd)
example_target = np.array([0, 0, 0, 0, 0, 0, 0, 0, 0, 1])
pdata, plabels = backdoor.poison(x_test, y=example_target)
plt.imshow(pdata[0].squeeze())
targets = to_categorical([9], 10)[0]
model = KerasClassifier(create_model())
proxy = AdversarialTrainerMadryPGD(KerasClassifier(create_model()),
nb_epochs=10, eps=0.15, eps_step=0.001)
proxy.fit(x_train, y_train)

{"model_id": "94cb68e8a094418a86faf2725f0effc0", "version_major": 2, "version_minor": 0}

{"model_id": "b91ef4cf71e54d3e86d43dcddb6222dd", "version_major": 2, "version_minor": 0}

```



Создать отравленные примеры данных

```

# конфигурируем атаку под модель Мэдри
attack = PoisoningAttackCleanLabelBackdoor(backdoor=backdoor,\
proxy_classifier=proxy.get_classifier(),\
target=targets, pp_poison=percent_poison,\
norm=2, eps=5, eps_step=0.1, max_iter=200)

```

```
# запускаем отравление
```

```
pdata, plabels = attack.poison(x_train, y_train)
```

```
{"model_id": "180e6727b91d4ab1a0e4d424979eafe6", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "4668565bd6684c08b7cfbd93a478f2fa", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "c4b8fd4d6c0044539f8170ad7534d9ea", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "99a75a40396e4a199e39c6c3ac690f82", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "ccd778c4377f4c7f9bc848afc8a2fc6b", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "0fbb4979e09343d687ba23ec0df7d19d", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "9728534b2f644ae688a54227934463ba", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "834ff6f4ddcc42ecb1d14c7399b95a18", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "f18a577f4b004c11b2c98d550ac8f3ba", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "1b2e911eb87d4a5c9d40576d23a98b14", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "cf3a9a52cbc443a08508a86ea4388bca", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "302cce45918a47a58ae6d9bed0339fc3", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "bac508b4699f4d449d1a9b132ab46373", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "eb51b8641c6241889b6f4b3b348797d2", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "75fa04c4a1444316b69d79604038e293", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "27e9c70483034a4e9ecf36a927999b7f", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "e9ee2ca829bd4cf587e831b51ff45383", "version_major": 2, "version_minor": 0}
```

```
{"model_id": "c6c8d82c47fa432782049100a6755cd7", "version_major": 2, "version_minor": 0}

{"model_id": "9e0526651c544515b41967628d74191d", "version_major": 2, "version_minor": 0}

{"model_id": "cb122b90b71347069c474c69778d3aea", "version_major": 2, "version_minor": 0}

{"model_id": "1cddbfd3057e46e8ad1ca872ae5230c9", "version_major": 2, "version_minor": 0}

{"model_id": "0c3f452c551b48b1a8c63452c21273a6", "version_major": 2, "version_minor": 0}
```


Обучить модель на отравленных данных

```
model.fit(pdata, plabels, nb_epochs=10)
```

Осуществить тест на чистой модели

```
# предсказываем на тестовых входах "здоровых" примеров
clean_preds = np.argmax(model.predict(x_test), axis=1)
# вычисляем среднюю точность предсказания на полном наборе тестов
clean_correct = np.sum(clean_preds == np.argmax(y_test, axis=1))
clean_total = y_test.shape[0]
clean_acc = clean_correct / clean_total
print("\nClean test set accuracy: %.2f%%" % (clean_acc * 100))
# отобразим картинку, ее класс, и предсказание для легитимного
# примера, чтобы
# показать как отравленная модель классифицирует легитимный пример
c = 0 # класс
i = 0 # изображение
c_idx = np.where(np.argmax(y_test, 1) == c)[0][i] # индекс картинки в массиве
# легитимных примеров
plt.imshow(x_test[c_idx].squeeze())
plt.show()
clean_label = c
print("Prediction: " + str(clean_preds[c_idx]))
```

Clean test set accuracy: 98.31%




Prediction: 0

Результаты атаки на модель:

```
not_target = np.logical_not(np.all(y_test == targets, axis=1))
px_test, py_test = backdoor.poisson(x_test[not_target],
y_test[not_target])
poison_preds = np.argmax(model.predict(px_test), axis=1)
poison_correct = np.sum(poison_preds == np.argmax(y_test[not_target],
axis=1))
poison_total = poison_preds.shape[0]
poison_acc = poison_correct / poison_total
print("\nPoison test set accuracy: %.2f%%" % (poison_acc * 100))
c = 0 # index to display
plt.imshow(px_test[c].squeeze())
plt.show()
clean_label = c
print("Prediction: " + str(poison_preds[c]))
```

Poison test set accuracy: 3.30%



Prediction: 9